



**DEPARTAMENTO  
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

# Trabajo Práctico

---

26 de Mayo de 2016

Inferencia Bayesiana

Integrante	LU	Correo electrónico
Costa, Manuel José Joaquín	035/14	manucos94@gmail.com
Gatti, Mathias Nicolás	477/14	mathigatti@gmail.com



**Facultad de Ciencias Exactas y Naturales**  
**Universidad de Buenos Aires**

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359


<http://www.fcen.uba.ar>

# Índice

<b>1. Ejercicio 1</b>	<b>3</b>
<b>2. Ejercicio 2</b>	<b>4</b>
2.1. Histogramas . . . . .	5
2.2. Correlaciones . . . . .	6
2.3. Media y Desvío Standard . . . . .	7
<b>3. Ejercicio 3</b>	<b>8</b>
<b>4. Ejercicio 4</b>	<b>9</b>

# 1. Ejercicio 1

El modelo que escogimos se describe a continuación, en este entran en juego distintos parametros de distribuciones que modelan el problema y datos obtenidos que nos ayudaran a predecir mejor las distribuciones de los parámetros. Los cálculos de inferencia se realizaran con JAGS. Mas adelante se describe el código utilizado en el código del modelo.



$$\begin{aligned} \beta &\sim \text{Categorical}(p_i) \\ \theta_1 &\sim \begin{cases} \text{Beta}(0.5, 0.5) & \text{if } \beta = 1 \\ \text{Beta}(100, 100) & \text{if } \beta \neq 1 \end{cases} \\ k_1 &\sim \text{Binomial}(\theta_1, n) \\ k_2 &\sim \text{Binomial}(\theta_2, n) \\ k_3 &\sim \text{Binomial}(\theta_3, n) \\ n &= 10 \end{aligned}$$

```

model{
  # Observed Counts
  k1 ~ dbin(theta1,n)
  k2 ~ dbin(theta2,n)
  k3 ~ dbin(theta3,n)

  # Prior on Rates Theta
  theta1 ~ dbeta(param1, param1)
  theta2 ~ dbeta(param2, param2)
  theta3 ~ dbeta(param3, param3)

  # Auxiliary variables for Theta's distribution
  param1 <- ifelse(alpha== 1, 0.5, 100)
  param2 <- ifelse(alpha== 2, 0.5, 100)
  param3 <- ifelse(alpha== 3, 0.5, 100)

  # Prior on Rate Alpha
  for( i in 1:3){
    pi[i] <- 1/3
  }
  alpha ~ dcat(pi[])
}

```

## 2. Ejercicio 2

Como valores iniciales de las variables no observadas escogimos distintas opciones para asegurarnos de que no haya diferencia en los valores a los cuales convergen. Para los gráficos expuestos se utilizaron los siguientes parámetros para el algoritmo de muestreo.

```
% Sampling
%MCMC Parameters
nchains = 2; %How Many Chains?
nburnin = 10e2; %How Many Burn-in Samples?
nsamples = 10e4; %How Many Recorded Samples?
nthin = 1; %How Often is a Sample Recorded?
doparallel = 0; % Parallel Option

% Assign Matlab Variables to the Observed Nodes
datastruct = struct('k1',k1,'k2',k2,'k3',k3,'n',n);

% Initialize Unobserved Variables
for i=1:nchains
    S.theta1 = 0.5; % Intial Value
    S.theta2 = 0.8; % Intial Value
    S.theta3 = 0.5; % Intial Value
    S.alpha = randi([1 3]); % Intial Value
    init0(i) = S;
end
```

## 2.1. Histogramas




Figura 1: Histograma de la variable  $\alpha$ .




Figura 2: Histograma de la variable  $\theta_1$ . La línea azul es una aproximación con una distribución normal.





Figura 3: Histograma de la variable  $\theta_3$ . La línea azul es una aproximación (Poco precisa como se podrá observar) con una distribución normal.

Figura 4: Histograma de la variable  $\theta_2$ . La línea azul es una aproximación con una distribución normal.

## 2.2. Correlaciones






Figura 5: Correlación entre  $\theta_1$  y  $\theta_2$ .

Figura 6: Correlación entre  $\theta_1$  y  $\theta_3$ .

Figura 7: Correlación entre  $\theta_1$  y  $\theta_2$ .

### 2.3. Media y Desvío Standard

media\_alpha = 2.9907

desvioStandard\_alpha = 0.1270

media\_t1 = 0.4899

desvioStandard\_t1 = 0.0368

media\_t2 = 0.4951

desvioStandard\_t2 = 0.0354

media\_t3 = 0.9523

desvioStandard\_t3 = 0.0680

### 3. Ejercicio 3

Esencialmente la diferencia va a tener que estar al nivel de los hiperparámetros, pues antes cada moneda no era indistinta a que las otras estuvieran cargadas o no, pero en este caso sí lo son. Por lo tanto, en lugar de tener un solo  $\alpha$ , ahora tendremos tres  $\alpha_i$ , con distribución Bernoulli de probabilidad  $\frac{1}{2}$  cada una como *prior*. En la figura 8 puede verse el nuevo modelo y la representación gráfica del mismo usando DAGs.

```
model{
  # Observed Counts
  k1 ~ dbin(theta1,n)
  k2 ~ dbin(theta2,n)
  k3 ~ dbin(theta3,n)

  # Prior on Rates Theta
  theta1 ~ dbeta(param1, param1)
  theta2 ~ dbeta(param2, param2)
  theta3 ~ dbeta(param3, param3)

  # Auxiliary variables
  for Theta's distribution
  param1 <- ifelse(alpha1=1, 0.5, 100)
  param2 <- ifelse(alpha2=2, 0.5, 100)
  param3 <- ifelse(alpha3=3, 0.5, 100)

  # Prior on Rates Alpha
  alpha1 ~ dbern(0.5)
  alpha2 ~ dbern(0.5)
  alpha3 ~ dbern(0.5)
}
```




Figura 8: El modelo propuesto junto con su representación gráfica.



## 4. Ejercicio 4

$$\begin{aligned} P(cara_i|D) &= \int P(cara_i, \theta_i|D) d\theta_i \\ &= \int P(cara_i|D, \theta_i) P(\theta_i|D) d\theta_i \\ &= \int P(cara_i|\theta_i) P(\theta_i|D) d\theta_i \\ &= \int \theta_i \sum_j P(\theta_i, \alpha = j|D) d\theta_i \\ &\propto \int \theta_i \sum_j P(D|\theta_i, \alpha = j) P(\theta_i, \alpha = j) d\theta_i \\ &= \int \theta_i \sum_j P(D|\theta_i) P(\theta_i|\alpha = j) P(\alpha = j) d\theta_i \end{aligned} \tag{1}$$