



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA

Trabajo Práctico

26 de Mayo de 2016

Inferencia Bayesiana

Integrante	LU	Correo electrónico
Costa, Manuel José Joaquín	035/14	manucos94@gmail.com
Gatti, Mathias Nicolás	477/14	mathigatti@gmail.com



Facultad de Ciencias Exactas y Naturales
Universidad de Buenos Aires

Ciudad Universitaria - (Pabellón I/Planta Baja)

Intendente Güiraldes 2160 - C1428EGA

Ciudad Autónoma de Buenos Aires - Rep. Argentina

Tel/Fax: (54 11) 4576-3359


<http://www.fcen.uba.ar>

Índice

1. Ejercicio 1	3
2. Ejercicio 2	4
2.1. Histogramas	5
2.2. Correlaciones	6
2.3. Media y Desvío Standard	7
3. Ejercicio 3	8
4. Ejercicio 4	9

1. Ejercicio 1

El modelo que escogimos se describe a continuación, en este entran en juego distintos parametros de distribuciones que modelan el problema y datos obtenidos que nos ayudaran a predecir mejor las distribuciones de los parámetros. Los cálculos de inferencia se realizaran con JAGS. Mas adelante se describe el código utilizado en el código del modelo.



$$\begin{aligned} \beta &\sim \text{Categorical}(p_i) \\ \theta_1 &\sim \begin{cases} \text{Beta}(0,5,0,5) & \text{if } \beta = 1 \\ \text{Beta}(100,100) & \text{if } \beta \neq 1 \end{cases} \\ k_1 &\sim \text{Binomial}(\theta_1, n) \\ k_2 &\sim \text{Binomial}(\theta_2, n) \\ k_3 &\sim \text{Binomial}(\theta_3, n) \\ n &= 10 \end{aligned}$$

```
model{
  # Observed Counts
  k1 ~ dbin(theta1,n)
  k2 ~ dbin(theta2,n)
  k3 ~ dbin(theta3,n)

  # Prior on Rates Theta
  theta1 ~ dbeta(param1, param1)
  theta2 ~ dbeta(param2, param2)
  theta3 ~ dbeta(param3, param3)

  # Auxiliary variables for Theta's distribution
  param1 <- ifelse(alpha== 1, 0.5, 100)
  param2 <- ifelse(alpha== 2, 0.5, 100)
  param3 <- ifelse(alpha== 3, 0.5, 100)

  # Prior on Rate Alpha
  for( i in 1:3){
    pi[i] <- 1/3
  }
  alpha ~ dcat(pi[])
}
```

2. Ejercicio 2

Como valores iniciales de las variables no observadas escogimos distintas opciones para asegurarnos de que no haya diferencia en los valores a los cuales convergen. Para los gráficos expuestos se utilizaron los siguientes parámetros para el algoritmo de muestreo.

```
% Sampling
%MCMC Parameters
nchains = 2; %How Many Chains?
nburnin = 10e2; %How Many Burn-in Samples?
nsamples = 10e4; %How Many Recorded Samples?
nthin = 1; %How Often is a Sample Recorded?
doparallel = 0; %Parallel Option

% Assign Matlab Variables to the Observed Nodes
datastruct = struct('k1',k1,'k2',k2,'k3',k3,'n',n);

% Initialize Unobserved Variables
for i=1:nchains
    S.theta1 = 0.5; %Intial Value
    S.theta2 = 0.8; %Intial Value
    S.theta3 = 0.5; %Intial Value
    S.alpha = randi([1 3]); %Intial Value
    init0(i) = S;
end
```

2.1. Histogramas




Figura 1: Histograma de la variable α .




Figura 2: Histograma de la variable θ_1 . La línea azul es una aproximación con una distribución normal.




Figura 3: Histograma de la variable θ_3 . La línea azul es una aproximación (Poco precisa como se podrá observar) con una distribución normal.




Figura 4: Histograma de la variable θ_2 . La línea azul es una aproximación con una distribución normal.

2.2. Correlaciones




Figura 5: Correlación entre θ_1 y θ_2 .




Figura 6: Correlación entre θ_1 y θ_3 .




Figura 7: Correlación entre θ_1 y θ_2 .

2.3. Media y Desvío Standard

media_alpha = 2.9907

desvioStandard_alpha = 0.1270

media_t1 = 0.4899

desvioStandard_t1 = 0.0368

media_t2 = 0.4951

desvioStandard_t2 = 0.0354

media_t3 = 0.9523

desvioStandard_t3 = 0.0680

3. Ejercicio 3

Esencialmente la diferencia va a tener que estar al nivel de los hiperparámetros, pues antes cada moneda no era indistinta a que las otras estuvieran cargadas o no, pero en este caso sí lo son. Por lo tanto, en lugar de tener un solo α , ahora tendremos tres α_i , con distribución Bernoulli de probabilidad $\frac{1}{2}$ cada una como *prior*. En la figura 8 puede verse el nuevo modelo y la representación gráfica del mismo usando DAGs.

```
model{
  # Observed Counts
  k1 ~ dbin(theta1,n)
  k2 ~ dbin(theta2,n)
  k3 ~ dbin(theta3,n)

  # Prior on Rates Theta
  theta1 ~ dbeta(param1, param1)
  theta2 ~ dbeta(param2, param2)
  theta3 ~ dbeta(param3, param3)

  # Auxiliary variables
  for Theta's distribution
  param1 <- ifelse(alpha1=1, 0.5, 100)
  param2 <- ifelse(alpha2=2, 0.5, 100)
  param3 <- ifelse(alpha3=3, 0.5, 100)

  # Prior on Rates Alpha
  alpha1 ~ dbern(0.5)
  alpha2 ~ dbern(0.5)
  alpha3 ~ dbern(0.5)
}
```




Figura 8: El modelo propuesto junto con su representación gráfica.

4. Ejercicio 4

A continuación desarrollamos la expresión para la probabilidad de obtener cara en la siguiente tirada de cualquiera de las tres monedas, aprovechando la información previa. Usamos fundamentalmente las tres propiedades vistas en clase: marginalización, reescritura de la probabilidad conjunta con probabilidad condicional, y la falacia del jugador.

$$\begin{aligned}
 P(\text{cara}_i|D) &= \int P(\text{cara}_i, \theta_i|D)d\theta_i \\
 &= \int P(\text{cara}_i|D, \theta_i)P(\theta_i|D)d\theta_i \\
 &= \int P(\text{cara}_i|\theta_i)P(\theta_i|D)d\theta_i \\
 &= \int \theta_i(P(\theta_i, \alpha = i|D) + P(\theta_i, \alpha \neq i|D))d\theta_i \\
 &= \int \theta_i(P(\theta_i|\alpha = i, D)P(\alpha = i|D) + P(\theta_i|\alpha \neq i, D)P(\alpha \neq i|D))d\theta_i
 \end{aligned} \tag{1}$$

En la última línea de esta ecuación podemos identificar las siguientes fuentes de incertidumbre:

- La incerteza inherente al *rate* de la moneda;
- La incerteza de la *posterior* de θ_i separando en los casos en que el modelo determina que i es la moneda cargada y los que no (recordar que el *prior* utilizado para θ_i es condicional a este hecho);
- La incerteza de determinar si una moneda está cargada o no (usando la *posterior* de α).